



决策树

ID3、C4.5 与 CART 算法及实现

胡煜程，张之恒，吴皓阳，张鑫月

2025 年 4 月 7 日



天津大学
Tianjin University



目录

- ▶ 引言
- ▶ 特征选择
- ▶ 决策树生成
- ▶ 决策树剪枝
- ▶ CART 算法
- ▶ 算法对比总结
- ▶ 代码实现与实验结果
- ▶ 总结



Table of Contents

1 引言

► 引言

► 特征选择

► 决策树生成

► 决策树剪枝

► CART 算法

► 算法对比总结

► 代码实现与实验结果


► 总结



什么是决策树?

1 引言

- 决策树是一种树形结构的监督学习模型
- 每个内部节点表示一个特征上的测试
- 每个分支代表测试结果
- 每个叶节点代表一个类别标签
- 优点：可解释性强、无需特征缩放、处理混合数据
- 应用：分类、回归、特征选择





决策树学习的核心问题

1 引言

三大核心问题

1. 特征选择：每个节点选择哪个特征进行划分？
2. 树的生成：如何递归地构建决策树？
3. 树的剪枝：如何防止过拟合、提升泛化能力？

算法	特征选择准则	树类型	剪枝
ID3	信息增益	多叉树	无
C4.5	信息增益比	多叉树	悲观剪枝
CART	基尼指数/MSE	二叉树	代价复杂度剪枝



Table of Contents

2 特征选择

- ▶ 引言
- ▶ 特征选择
- ▶ 决策树生成
- ▶ 决策树剪枝
- ▶ CART 算法
- ▶ 算法对比总结
- ▶ 代码实现与实验结果
- ▶ 总结



特征选择

2 特征选择

- 信息熵与信息增益
- 信息增益比
- 基尼指数



天津大学
Tianjin University



信息熵

2 特征选择

信息熵（Shannon Entropy）衡量数据集的不确定性：

$$H(D) = - \sum_{k=1}^K p_k \log_2 p_k \quad (1)$$

其中 p_k 是类别 k 在数据集 D 中的比例。

示例

性质

- $H(D) \geq 0$
- 越纯净，熵越小
- 完全均匀时熵最大： $H = \log_2 K$

二分类，各占 50%：

$$H = -0.5 \log_2 0.5 - 0.5 \log_2 0.5 = 1$$

二分类，一类占 90%：

$$H \approx 0.469$$



条件熵与信息增益

2 特征选择

条件熵：在已知特征 A 的条件下， D 的不确定性：

$$H(D | A) = \sum_v \frac{|D_v|}{|D|} H(D_v) \quad (2)$$

信息增益（ID3 使用）：特征 A 对数据集 D 的信息增益：

$$IG(D, A) = H(D) - H(D | A) \quad (3)$$

特征选择准则

选择信息增益最大的特征作为当前节点的划分特征。

缺陷

信息增益偏向于选择取值数目多的特征（如编号、ID 等），导致过拟合。



信息增益比 (C4.5)

2 特征选择

C4.5 引入分裂信息 (Split Information) 来惩罚取值多的特征:

$$SI(D, A) = - \sum_v \frac{|D_v|}{|D|} \log_2 \frac{|D_v|}{|D|} \quad (4)$$

信息增益比:

$$IGR(D, A) = \frac{IG(D, A)}{SI(D, A)} \quad (5)$$

优点

- 减少对多值特征的偏好
- 更加公平地衡量特征

注意

当 $SI(D, A)$ 极小时, 增益比可能很大但无意义。C4.5 实践中先过滤信息增益低于均值的特征, 再取最大增益比。



基尼指数 (CART)

2 特征选择

基尼指数衡量数据集的不纯度:

$$\text{Gini}(D) = 1 - \sum_{k=1}^K p_k^2 \quad (6)$$

特征 A 的某二元划分 $\{D_1, D_2\}$ 的基尼指数:

$$\text{Gini}(D, A) = \frac{|D_1|}{|D|} \text{Gini}(D_1) + \frac{|D_2|}{|D|} \text{Gini}(D_2) \quad (7)$$

度量	计算量	对多分类
信息熵	含对数, 较慢	直接支持
基尼指数	无对数, 快速	需二值化



Table of Contents

3 决策树生成

- ▶ 引言
- ▶ 特征选择
- ▶ 决策树生成
- ▶ 决策树剪枝
- ▶ CART 算法
- ▶ 算法对比总结
- ▶ 代码实现与实验结果
- ▶ 总结



决策树生成

3 决策树生成

- ID3 算法
- C4.5 算法



天津大学
Tianjin University



ID3 算法

3 决策树生成

算法流程

1. 若 D 中所有样本属于同一类 C_k , 返回叶节点 (类 C_k)
2. 若特征集为空, 返回叶节点 (多数类)
3. 计算所有特征的信息增益, 选最大者 A^*
4. 对 A^* 的每个取值 a_v , 生成子节点
5. 若 D_v 为空, 返回叶节点 (多数类)
6. 否则递归建子树

局限性

- 只能处理离散特征
- 偏向多值特征
- 没有剪枝, 易过拟合
- 不能处理缺失值

终止条件

- 节点纯净 (熵为 0)
- 特征耗尽
- 子集为空



C4.5 算法

3 决策树生成

C4.5 是 ID3 的改进版本，解决了其主要局限：

问题	ID3	C4.5 改进
特征偏好	信息增益（偏多值）	信息增益比
连续特征	不支持	二分离散化
缺失值	不处理	加权处理
过拟合	无剪枝	悲观错误剪枝

连续特征处理（二分法）

对连续特征 A ，将样本按 A 值排序，取相邻值均值作为候选切分点 t ，计算每个 t 的信息增益比，选最优切分点将 A 二值化： $A \leq t$ 或 $A > t$ 。



Table of Contents

4 决策树剪枝

- ▶ 引言
- ▶ 特征选择
- ▶ 决策树生成
- ▶ 决策树剪枝
- ▶ CART 算法
- ▶ 算法对比总结
- ▶ 代码实现与实验结果
- ▶ 总结



决策树剪枝

4 决策树剪枝

- 过拟合问题
- 预剪枝与后剪枝



天津大学
Tianjin University



为什么需要剪枝?

4 决策树剪枝

- 决策树若完全生长，会记住训练集，泛化能力差
- 剪枝通过减小树的复杂度来提升泛化能力
- 预剪枝 (Pre-pruning):
在生成过程中提前停止
 - 限制最大深度、最小样本数
 - 划分后验证集精度无提升则停止
- 后剪枝 (Post-pruning):
先完整生成，再自底向上剪枝
 - 悲观错误剪枝 (C4.5)
 - 代价复杂度剪枝 (CART)

偏差-方差权衡

- 树过深 $\Rightarrow$ 低偏差，高方差
- 树过浅 $\Rightarrow$ 高偏差，低方差
- 剪枝寻找最优平衡点



CART 代价复杂度剪枝 (CCP)

4 决策树剪枝

CART 使用代价复杂度剪枝 (Cost-Complexity Pruning):

$$C_{\alpha}(T) = C(T) + \alpha \cdot |T| \quad (8)$$

其中 $C(T)$ 为树 T 的训练误差, $|T|$ 为叶节点数, $\alpha \geq 0$ 为复杂度参数。

剪枝过程

1. 生成完整树 T_0
2. 对每个内部节点 t , 计算剪枝收益 $g(t) = \frac{C(t) - C(T_t)}{|T_t| - 1}$
3. 剪掉 $g(t)$ 最小的子树, 得 T_1
4. 重复直到只剩根节点, 得到序列 $T_0 \supset T_1 \supset \dots$
5. 用交叉验证选最优 α , 从而选最优子树



Table of Contents

5 CART 算法

- ▶ 引言
- ▶ 特征选择
- ▶ 决策树生成
- ▶ 决策树剪枝
- ▶ CART 算法
- ▶ 算法对比总结
- ▶ 代码实现与实验结果
- ▶ 总结



CART 算法

5 CART 算法

- 分类树
- 回归树



天津大学
Tianjin University



CART 算法概述

5 CART 算法

CART (Classification And Regression Tree) 是一种生成二叉树的算法:

分类树

- 划分准则: 基尼指数最小化
- 叶节点输出: 多数类
- 支持离散与连续特征
- 每次二值划分

回归树

- 划分准则: 均方误差最小化
- 叶节点输出: 均值
- 连续输出变量
- 切分点穷举搜索

回归树划分准则

对特征 j 和切分点 s , 寻找使两子区域内 MSE 之和最小的 (j^*, s^*) :

$$\min_{j,s} \left[\min_{c_1} \sum_{x_i \in D_1} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in D_2} (y_i - c_2)^2 \right] \quad (9)$$



CART 分类树完整流程

5 CART 算法

1. 输入：训练集 D ，基尼指数阈值 ε ，最小样本数
2. 若 D 中样本属于同一类，返回叶节点
3. 对所有特征 A 及其所有可能划分点 (A, a) ，计算 $\text{Gini}(D, A = a)$
4. 选基尼指数最小的特征 A^* 及切分点 a^* ，将 D 分为 D_1, D_2
5. 对 D_1, D_2 递归调用上述步骤
6. 停止条件：
 - 节点样本数 $<$ 最小阈值
 - 基尼指数 $< \varepsilon$
 - 无可用特征
7. 对生成的完整树进行代价复杂度剪枝



Table of Contents

6 算法对比总结

- ▶ 引言
- ▶ 特征选择
- ▶ 决策树生成
- ▶ 决策树剪枝
- ▶ CART 算法
- ▶ 算法对比总结
- ▶ 代码实现与实验结果
- ▶ 总结



三种算法横向对比

6 算法对比总结

属性	ID3	C4.5	CART
提出年份	1986	1993	1984
特征选择	信息增益	信息增益比	基尼指数/MSE
树结构	多叉树	多叉树	二叉树
连续特征	×	✓	✓
缺失值	×	✓	✓
剪枝	×	悲观剪枝	CCP 剪枝
任务类型	分类	分类	分类 + 回归

实践建议

- 离散数据小实验 → ID3 (原理清晰)
- 含连续特征的分类 → C4.5 (更健壮)
- 需要回归或内置到集成方法 → CART (sklearn 默认)



Table of Contents

7 代码实现与实验结果

- ▶ 引言
- ▶ 特征选择
- ▶ 决策树生成
- ▶ 决策树剪枝
- ▶ CART 算法
- ▶ 算法对比总结
- ▶ 代码实现与实验结果
- ▶ 总结



代码实现与实验结果

7 代码实现与实验结果

- 数据集：
StudentPerformanceFactors_binary_68.csv
- ID3、C4.5、CART 复现结果
- 开源代

码:github.com/kekeaii/machine_learning



天津大学
Tianjin University



数据集介绍: StudentPerformanceFactors_binary_68.csv

7 代码实现与实验结果

- 数据集:
StudentPerformanceFactors_binary_68.csv
- 样本数: 1000 (实验中取前 1000 条)
- 特征数: 19
- 目标变量: 是否达到 68 分及以上
- 主要特征包括:
 - Attendance
 - Hours_Studied
 - Previous_Scores
 - Parental_Involvement

数据预处理

- 原始数据来自
StudentPerformanceFactors.xlsx
- 缺失值处理: 无缺失
- 删除原始分数字段 Exam_Score
- 标签二值化: $\text{Exam_Score} \geq 68$ 记为 1, 否则记为 0
- ID3 / C4.5 将特征统一视为离散特征
- CART 对类别特征进行整数编码
- 训练/测试划分 = 8:2



实现框架

7 代码实现与实验结果

三种算法均使用 Python 实现，核心代码结构如下：

代码结构

```
decision_tree/  
  decision_tree_id3_c45.py          # ID3 / C4.5 实现  
  cart_classification.py            # CART 分类树实现  
  eval_student_binary_id3_c45.py   # ID3 / C4.5 实验脚本  
  eval_student_binary_cart.py      # CART 实验脚本  
  StudentPerformanceFactors.xlsx    # 原始数据  
  StudentPerformanceFactors_binary.csv  
  StudentPerformanceFactors_binary_68.csv  
  README.md                        # 实验说明与命令
```



实验结果：准确率对比

7 代码实现与实验结果

算法	训练集准确率	测试集准确率	树深度
ID3	100.00%	71.00%	4
C4.5	100.00%	73.00%	7
CART	100.00%	80.50%	16

Table: 三种算法在 StudentPerformanceFactors_binary_68.csv 上的性能对比

观察与分析

- CART 在测试集上表现最优，准确率为 80.50%。
- 三种算法在训练集上均达到 100%，说明都具有较强的拟合能力。
- ID3 与 C4.5 的泛化能力弱于 CART，其中 ID3 测试集准确率最低。
- CART 的树深度最大，为 16，但其测试表现仍最好，说明基尼指数划分在该任务上更有效



实验结果：混淆矩阵

7 代码实现与实验结果

ID3

	Pred+	Pred-
Act+	52	35
Act-	23	90

精确率：69.33%

召回率：59.77%

C4.5

	Pred+	Pred-
Act+	63	24
Act-	30	83

精确率：67.74%

召回率：72.41%

CART

	Pred+	Pred-
Act+	67	20
Act-	19	94

精确率：77.91%

召回率：77.01%

- ID3 的漏判较多，召回率最低。
- C4.5 在召回率上优于 ID3，但误报数量更多。
- CART 在精确率与召回率之间取得了最好的平衡，整体分类效果最佳。



决策树结构：关键节点

7 代码实现与实验结果

层级	节点特征	划分条件	说明
第 0 层（根节点）	Attendance	$\leq 79.5 / > 79.5$	最强判别特征
第 1 层	Hours_Studied	$\leq 23.5 / > 23.5$	学习时长次强
第 1 层	Previous_Scores	$\leq 67.5 / > 67.5$	历史成绩辅助
第 2 层	Sleep_Hours	$\leq 6.5 / > 6.5$	睡眠影响较弱
叶节点	—	输出 Pass / Fail	多数类决策

Table: CART 决策树关键分裂节点（前三层）

结构说明

根节点以 **Attendance**（出勤率）进行首次划分，与特征重要性排名一致；树共 16 层，叶节点输出类别由该叶中多数样本决定。



特征重要性分析

7 代码实现与实验结果

排名	特征名称	重要性得分	累计占比
1	Attendance	0.3884	38.84%
2	Hours_Studied	0.2876	67.60%
3	Previous_Scores	0.1011	77.71%
4	Sleep_Hours	0.0357	81.28%
5	Access_to_Resources	0.0350	84.78%
—	其余特征合计	0.1522	100.00%

Table: CART 模型特征重要性排名（基于基尼指数下降量）

结论

Attendance（出勤率）是最强预测因子，重要性接近 40%；前三个特征累计解释了约 77.7% 的不纯度下降，说明该任务的预测信息高度集中。



Table of Contents

8 总结

- ▶ 引言
- ▶ 特征选择
- ▶ 决策树生成
- ▶ 决策树剪枝
- ▶ CART 算法
- ▶ 算法对比总结
- ▶ 代码实现与实验结果
- ▶ 总结



总结

8 总结

- 特征选择是决策树的核心：
 - 信息增益 (ID3) → 偏多值特征
 - 信息增益比 (C4.5) → 更公平
 - 基尼指数 (CART) → 计算高效
- 剪枝是防止过拟合的关键手段
- 在实验数据集上, CART 取得最优效果, 测试集准确率达 80.50%
- 决策树是集成方法 (随机森林、GBDT) 的基础组件

未来工作

- 超参数调优 (最大深度、最小叶节点数)
- 与随机森林、XGBoost 对比
- 处理类别不平衡问题
- 特征工程改进



决策树

Thank you for listening!
Any questions?